

整段对话 Embedding 相似度分析

来源 embedding_full_dialogue_results · 模型 Qwen3-Embedding-4B · 9 cases × 6 组 × 10 runs · 对每组取 10 段 full_dialogue 编码后求平均向量 · 度量 = 余弦相似度

0.983

噪声地板 (同模型重跑)

0.947

跨模型平均相似度 (信号)

0.053

跨模型平均距离 (1-相似度)


3.2×

信噪比 (跨模型距离/噪声距离)

结论：噪声地板高且稳定，跨模型差异清晰可辨

同一模型重跑两次的相似度（噪声地板） ≈ 0.983 （pro 0.986 / flash 0.985 / qwen 0.980），非常高且稳定；
跨模型相似度 ≈ 0.947 ，明显更低。以“距离=1-相似度”衡量，跨模型距离是噪声地板的约 3.2 $\times$ ，
差异真实可辨。还能看出模型家族层级：flash 与 pro 同属 deepseek，彼此最像（0.978）；qwen 离两者都远。


组级 **6×6** 余弦相似度方阵（对角线块 = 同模型两次重复 = 噪声地板）



模型层对比 与 两两相似度明细

模型层 3×3 相似度方阵（合并两次重复）

	flash	pro	qwen
flash	1.000	0.978	0.950
pro	0.978	1.000	0.937
qwen	0.950	0.937	1.000



组级两两相似度（升序；绿 = 同模型重跑 = 噪声地板）

对比	平均相似度	标准差	最小	最大	类型
qwen_2 vs pro_1	0.9271	0.0278	0.8668	0.9560	跨模型
qwen_2 vs pro_2	0.9290	0.0282	0.8686	0.9585	跨模型
qwen_1 vs pro_1	0.9300	0.0302	0.8717	0.9597	跨模型
qwen_1 vs pro_2	0.9312	0.0309	0.8785	0.9623	跨模型
qwen_2 vs flash_1	0.9388	0.0193	0.8957	0.9600	跨模型
qwen_1 vs flash_1	0.9400	0.0162	0.9125	0.9568	跨模型
qwen_2 vs flash_2	0.9421	0.0228	0.8856	0.9632	跨模型
qwen_1 vs flash_2	0.9452	0.0209	0.9089	0.9662	跨模型
flash_1 vs pro_2	0.9684	0.0125	0.9443	0.9843	跨模型
flash_2 vs pro_2	0.9700	0.0114	0.9480	0.9844	跨模型
flash_1 vs pro_1	0.9705	0.0143	0.9386	0.9836	跨模型
flash_2 vs pro_1	0.9739	0.0073	0.9628	0.9856	跨模型
qwen_1 vs qwen_2	0.9796	0.0102	0.9615	0.9859	噪声地板
flash_1 vs flash_2	0.9845	0.0068	0.9695	0.9928	噪声地板
pro_1 vs pro_2	0.9862	0.0048	0.9791	0.9936	噪声地板

方法说明 · 与诊断字符串分桶法的对比

本方法（**embedding**）流程

1. 每个 case、每个组取 10 段 full_dialogue（完整医患问诊全过程，约 6000 字符/段）。

2. 用 Qwen3-Embedding-4B 把每段对话编码为向量，组内求平均并归一化，得到“该组在该 case 的代表向量”。

3. 计算各组两两余弦相似度，再对 9 个 case 求平均，得到相似度方阵。

4. 同模型两次重复(_1/_2)的相似度 = 噪声地板；不同模型之间 = 信号。

两种方法对比

维度	诊断字符串 + exact 分桶 + JS 散度	整段对话 + embedding + 余弦(本法)
比较对象	仅最终诊断字符串	整段问诊对话(信息量大)
量化方式	exact 精确匹配分桶	语义向量
度量	JS 散度(越大越不同)	余弦相似度(越大越像)
对文字外壳	敏感(大小写/标点/后缀都算不同桶)	不敏感(只看语义)
主要问题	default 自由文本→大量碎桶→假性高散度	规避了文字外壳噪声

要点

embedding 法给出的噪声地板(同模型重跑≈0.985)与跨模型信号(≈0.947)差距清晰稳定，且不受文字外壳噪声干扰；

比之前在诊断字符串上做 exact 分桶 + JS 散度更干净，能更可靠地反映模型间的真实分歧，适合作为版本/能力变化的指纹基线。