

整段对话 Embedding 相似度分析

来源 embedding_full_dialogue_results_gpt_8b · 模型 Qwen3-Embedding-8B · 9 cases × 10 组 × 10 runs · 对每组取 10 段 full_dialogue 编码后求平均向量 · 度量 = 余弦相似度

0.984

噪声地板 (同模型重跑)

0.924

跨模型平均相似度 (信号)

0.076

跨模型平均距离 (1-相似度)


4.9×

信噪比 (跨模型距离/噪声距离)

结论：噪声地板高且稳定，跨模型差异清晰可辨

同一模型重跑两次的相似度（噪声地板）≈0.984（qwen 0.979 / flash 0.983 / pro 0.985 / gpt5.4.mini 0.987 / gpt5.5 0.987），非常高且稳定；跨模型相似度 ≈0.924，明显更低。以“距离=1-相似度”衡量，跨模型距离是噪声地板的约 4.9×，差异真实可辨。也能看出模型家族层级：同家族（如 deepseek 的 flash/pro、GPT 的 5.4mini/5.5）彼此最像。


组级 10×10 余弦相似度方阵（对角线块 = 同模型两次重复 = 噪声地板）



模型层对比 与 两两相似度明细

模型层 5×5 相似度方阵（合并两次重复）

	flash	pro	qwen	gpt5.4.mini	gpt5.5
flash	1.000	0.977	0.947	0.936	0.908
pro	0.977	1.000	0.935	0.946	0.918
qwen	0.947	0.935	1.000	0.902	0.888
gpt5.4.mini	0.936	0.946	0.902	1.000	0.956
gpt5.5	0.908	0.918	0.888	0.956	1.000



组级两两相似度（升序；绿 = 同模型重跑 = 噪声地板）

对比	平均相似度	标准差	最小	最大	类型
qwen_1 vs gpt5.5_2	0.8792	0.0316	0.8303	0.9248	跨模型
qwen_2 vs gpt5.5_2	0.8799	0.0324	0.8175	0.9340	跨模型
qwen_1 vs gpt5.5_1	0.8819	0.0318	0.8396	0.9169	跨模型
qwen_2 vs gpt5.5_1	0.8828	0.0316	0.8295	0.9319	跨模型
qwen_2 vs gpt5.4.mini_1	0.8941	0.0268	0.8522	0.9260	跨模型
qwen_2 vs gpt5.4.mini_2	0.8942	0.0297	0.8522	0.9365	跨模型
qwen_1 vs gpt5.4.mini_2	0.8946	0.0367	0.8285	0.9458	跨模型
qwen_1 vs gpt5.4.mini_1	0.8956	0.0340	0.8347	0.9394	跨模型
flash_1 vs gpt5.5_1	0.8987	0.0343	0.8474	0.9465	跨模型
flash_1 vs gpt5.5_2	0.9001	0.0337	0.8514	0.9492	跨模型
flash_2 vs gpt5.5_1	0.9015	0.0254	0.8623	0.9321	跨模型
flash_2 vs gpt5.5_2	0.9024	0.0300	0.8431	0.9360	跨模型
pro_2 vs gpt5.5_1	0.9077	0.0394	0.8357	0.9475	跨模型
pro_2 vs gpt5.5_2	0.9085	0.0410	0.8200	0.9471	跨模型
pro_1 vs gpt5.5_1	0.9144	0.0372	0.8478	0.9518	跨模型
pro_1 vs gpt5.5_2	0.9157	0.0422	0.8239	0.9569	跨模型
qwen_1 vs pro_1	0.9255	0.0309	0.8726	0.9532	跨模型
qwen_2 vs pro_1	0.9256	0.0276	0.8738	0.9563	跨模型
flash_1 vs gpt5.4.mini_1	0.9277	0.0183	0.8900	0.9509	跨模型
flash_2 vs gpt5.4.mini_1	0.9282	0.0061	0.9179	0.9356	跨模型
flash_1 vs gpt5.4.mini_2	0.9282	0.0239	0.8699	0.9466	跨模型
qwen_1 vs pro_2	0.9284	0.0285	0.8781	0.9536	跨模型
qwen_2 vs pro_2	0.9290	0.0232	0.8889	0.9562	跨模型

对比	平均相似度	标准差	最小	最大	类型
flash_2 vs gpt5.4.mini_2	0.9305	0.0133	0.9000	0.9466	跨模型
pro_2 vs gpt5.4.mini_1	0.9341	0.0108	0.9176	0.9505	跨模型
pro_2 vs gpt5.4.mini_2	0.9364	0.0151	0.9075	0.9538	跨模型
qwen_1 vs flash_1	0.9371	0.0182	0.9086	0.9594	跨模型
qwen_2 vs flash_1	0.9387	0.0181	0.9032	0.9614	跨模型
qwen_2 vs flash_2	0.9393	0.0186	0.8967	0.9591	跨模型
qwen_1 vs flash_2	0.9394	0.0202	0.9064	0.9601	跨模型
pro_1 vs gpt5.4.mini_1	0.9425	0.0119	0.9228	0.9603	跨模型
pro_1 vs gpt5.4.mini_2	0.9439	0.0123	0.9233	0.9591	跨模型
gpt5.4.mini_2 vs gpt5.5_2	0.9476	0.0344	0.8674	0.9788	跨模型
gpt5.4.mini_2 vs gpt5.5_1	0.9494	0.0271	0.8980	0.9832	跨模型
gpt5.4.mini_1 vs gpt5.5_2	0.9502	0.0300	0.8783	0.9771	跨模型
gpt5.4.mini_1 vs gpt5.5_1	0.9511	0.0242	0.9050	0.9833	跨模型
flash_1 vs pro_2	0.9661	0.0163	0.9327	0.9853	跨模型
flash_1 vs pro_1	0.9683	0.0156	0.9344	0.9836	跨模型
flash_2 vs pro_2	0.9684	0.0099	0.9572	0.9844	跨模型
flash_2 vs pro_1	0.9724	0.0098	0.9595	0.9864	跨模型
qwen_1 vs qwen_2	0.9794	0.0104	0.9568	0.9862	噪声地板
flash_1 vs flash_2	0.9829	0.0070	0.9668	0.9903	噪声地板
pro_1 vs pro_2	0.9853	0.0035	0.9814	0.9915	噪声地板
gpt5.5_1 vs gpt5.5_2	0.9869	0.0050	0.9789	0.9920	噪声地板
gpt5.4.mini_1 vs gpt5.4.mini_2	0.9874	0.0044	0.9766	0.9903	噪声地板

方法说明 · 与诊断字符串分桶法的对比

本方法（embedding）流程

- 1. 每个 case、每个组取 10 段 full_dialogue（完整医患问诊全过程，约 6000 字符/段）。
- 2. 用 Qwen3-Embedding-8B 把每段对话编码为向量，组内求平均并归一化，得到“该组在该 case 的代表向量”。
- 3. 计算各组两两余弦相似度，再对 9 个 case 求平均，得到相似度方阵。
- 4. 同模型两次重复(_1/_2)的相似度 = 噪声地板；不同模型之间 = 信号。

两种方法对比

维度	诊断字符串 + exact 分桶 + JS 散度	整段对话 + embedding + 余弦(本法)
比较对象	仅最终诊断字符串	整段问诊对话(信息量大)
量化方式	exact 精确匹配分桶	语义向量
度量	JS 散度(越大越不同)	余弦相似度(越大越像)
对文字外壳	敏感(大小写/标点/后缀都算不同桶)	不敏感(只看语义)
主要问题	default 自由文本→大量碎桶→假性高散度	规避了文字外壳噪声

要点

embedding 法给出的噪声地板(同模型重跑≈0.984)与跨模型信号(≈0.924)差距清晰稳定，且不受文字外壳噪声干扰；比之前在诊断字符串上做 exact 分桶 + JS 散度更干净，能更可靠地反映模型间的真实分歧，适合作为版本/能力变化的指纹基线。